

Oltre l'Attenzione Quadratica: Dai Transformer ai Modelli State-Space Olografici di Fourier

Analisi Teorica e Architetture Comparativa: Attention Softmax vs SSM a Stati Reali (Mamba) vs Modulazione di Fase Complessa (FSTLLM 2.0)

Progetto di Ricerca FSTLLM 2.0 — Documento Guida per Esposizione Accademica e Tesi Universitaria
Anno Accademico 2025/2026

Sommario Esecutivo (Abstract)

Questo documento fornisce una disamina teorico-architetture completa, appositamente strutturata per una presentazione o discussione d'esame universitario, sulle architetture avanzate per l'elaborazione del linguaggio naturale. A partire dalle intuizioni geometriche rese celebri da 3Blue1Brown, viene formalizzato il meccanismo di Softmax Attention nei Transformer e ne vengono dimostrati i limiti computazionali: la complessità quadratica $\mathcal{O}(S^2)$ in fase di addestramento e l'esplosione lineare del KV-Cache durante l'inferenza autoregressiva ($\mathcal{O}(S)$ di footprint di memoria). Vengono poi analizzati i modelli State-Space continui e discreti (S4, Mamba, RWKV) e i limiti fisici derivanti dai decadimenti monotoni ad autovalori reali. Infine, viene dettagliata l'architettura proposta **FSTLLM 2.0 (Fourier Space-Time LLM)**: la persistenza degli embedding densi in $\mathbb{R}^D$, l'introduzione della convoluzione locale depthwise causale per la micro-sintassi, la modulazione selettiva della fase angolare sul cerchio unitario $\mathbb{S}^1$, la memoria olografica complessa ad inferenza strettamente $\mathcal{O}(1)$, e il paradigma Grouped-Query Resonance (GQR) con rapporto 4:1 tra Query Heads e Memory Heads.

1. Fondamenti Geometrici e la Lezione di 3Blue1Brown

Per spiegare con efficacia le architetture neurali in sede accademica, è essenziale iniziare dalla prospettiva fondante del Deep Learning applicato al linguaggio: **la geometria degli spazi vettoriali ad alta dimensionalità**, così come illustrata da Grant Sanderson (3Blue1Brown) nei capitoli 5, 6 e 7 della serie *Neural Networks*.

L'Intuizione di 3Blue1Brown: Le Parole come Vettori e Direzioni Semantiche

Una rete neurale non opera direttamente su stringhe o simboli grafici discreti. Il primissimo passo consiste nel mappare ogni token di indice t in un vettore numerico reale continuo ad altissima dimensionalità (d_{model} , tipicamente tra 384 e 12.288):

$$\mathbf{x}_t^{(0)} = W_E[\text{token}_t] \in \mathbb{R}^{d_{\text{model}}}$$

dove $W_E \in \mathbb{R}^{V \times d_{\text{model}}}$ è la matrice di *embedding*. In questo spazio:

- **Vettori vicini** rappresentano parole con affinità semantiche o contestuali simili.
- **Le direzioni** (differenze vettoriali) incarnano specifici concetti (ad es. il vettore $\vec{v}_{\text{donna}} - \vec{v}_{\text{uomo}}$ è quasi parallelo a $\vec{v}_{\text{regina}} - \vec{v}_{\text{re}}$, così come esistono direzioni dedicate alla pluralità, alla desinenza verbale o ai ruoli grammaticali).

Tuttavia, l'embedding iniziale è un vettore **statico e decontestualizzato**: la parola “*banca*” assume lo stesso identico vettore sia che si parli di finanza sia che si parli dell'argine di un fiume.

Il Principio del “Context Soaking” (Assorbimento del Contesto)

Come spiegato nel Capitolo 5 di 3Blue1Brown, il compito dell'intera rete non è altro che permettere a ciascun vettore di **assorbire il contesto circostante** man mano che attraversa i diversi strati (layers). All'ingresso della rete il vettore esprime solo il significato isolato da vocabolario; all'uscita dall'ultimo blocco, lo stesso vettore è stato deformato, ruotato e arricchito per codificare l'intero scenario narrativo, grammaticale e logico indispensabile a predire il token successivo.

Indipendentemente dalla specifica architettura adottata, un blocco per Large Language Model moderno deve sempre assolvere a due ruoli distinti:

1. **Scambio di Informazione Temporale**: Permettere ai token distanti nella frase di dialogare e influenzarsi a vicenda.
2. **Memoria Associativa Non-Lineare**: Un modulo feed-forward (MLP o SwiGLU) che, applicato a ciascun token singolarmente e in parallelo, agisce come una memoria associativa chiave-valore per recuperare informazioni fattuali e pattern astratti appresi durante il training.

2. Il Transformer Classico e il Collo di Bottiglia dell'Attenzione

Il Transformer standard (Vaswani et al., 2017) implementa la comunicazione tra token per mezzo dell'operatore di **Scaled Dot-Product Attention**:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V$$

dove $Q = XW_Q$, $K = XW_K$, $V = XW_V$ e M rappresenta la matrice di mascheramento causale triangolare inferiore:

$$M_{i,j} = \begin{cases} 0 & \text{se } j \leq i \\ -\infty & \text{se } j > i \end{cases}$$

Matrice di Attenzione Causale Softmax ($S \times S$):					
	Token 1	Token 2	Token 3	...	Token S
Token 1	[1.0	0	0		0]
Token 2	[0.3	0.7	0		0]
Token 3	[0.1	0.4	0.5		0]
...	[...	...	...		...]
Token S	[$a_{\{S,1\}}$	$a_{\{S,2\}}$	$a_{\{S,3\}}$	...	$a_{\{S,S\}}$]

▲
Costo Computazionale: $O(S^2)$

La Metafora delle Query, Key e Value

Nella formulazione pedagogica di 3Blue1Brown:

- **Query (Q):** Rappresenta la domanda che il token corrente pone all'ambiente circostante (*"Sono un sostantivo singolare, cerco aggettivi o articoli che mi precedono"*).
- **Key (K):** Rappresenta l'etichetta descrittiva che ciascun token espone (*"Sono l'aggettivo 'blu' posizionato a $t - 2$ "*).
- **Dot-Product (QK^T):** Il prodotto scalare quantifica geometricamente la congruenza tra la domanda del primo token e l'offerta del secondo.
- **Softmax:** Normalizza la riga affinché la somma dei coefficienti valga 1, trasformando le affinità in percentuali di attenzione.
- **Value (V):** Contiene il reale pacchetto informativo da sommare al vettore target per arricchirne il significato.

I Due Limiti Strutturali Insuperabili del Transformer

1. **Costo di Addestramento Quadratico $O(S^2)$:** La costruzione della matrice di attenzione $S \times S$ richiede un numero di operazioni e un'allocazione di memoria che scalano con il quadrato della sequenza. Addestrare modelli con contesti di 64k o 1M token comporta una spesa computazionale gigantesca.
2. **Il Muro del KV-Cache durante l'Inferenza ($O(S)$ Memoria per Token):** Nella generazione autoregressiva (generazione un token alla volta):
 - Ad ogni nuovo step temporale t , per consentire alla Query del nuovo token di confrontarsi con tutte le parole del passato, il sistema deve conservare in VRAM l'intera storia dei vettori $K_{1:t}$ e $V_{1:t}$ per ogni livello della rete.
 - La dimensione di questo buffer (il **KV-Cache**) cresce linearmente con la lunghezza della conversazione ($O(S)$).
 - In produzione, il fattore limitante non è la potenza di calcolo (TFLOPS della GPU), bensì la **banda di memoria (Memory-Bandwidth Bound)**: per generare anche un solo singolo carattere, la GPU deve ricaricare decine di gigabyte di cache dalla VRAM ai registri.

3. Modelli State Space Lineari (SSM): S4, Mamba e RWKV

Per abbattere la barriera quadratica $O(S^2)$, la letteratura recente ha riscoperto la teoria classica dei sistemi dinamici a tempo continuo, introducendo i modelli **State Space (SSM)**:

$$\frac{dh(t)}{dt} = Ah(t) + Bx(t), \quad y(t) = Ch(t) + Dx(t)$$

Discretizzando il sistema continuo con un passo temporale Δ (mediante trasformazione Zero-Order Hold):

$$\bar{A} = \exp(\Delta A), \quad \bar{B} = (\Delta A)^{-1}(\bar{A} - I)(\Delta B)$$

ottenendo le equazioni ricorrenti discrete:

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t, \quad y_t = C_t h_t$$

Vantaggi Rivoluzionari degli SSM

- **Inferenza a Memoria e Tempo Rigorosamente Costante $\mathcal{O}(1)$:** Non esiste alcun KV-Cache. La storia passata viene compressa all'interno del vettore di stato latente $h_t \in \mathbb{R}^N$. Generare il token successivo costa sempre lo stesso tempo e occupa sempre gli stessi byte, sia al token 10 che al token 100.000.
- **Addestramento Parallelo $\mathcal{O}(S)$:** Grazie alla linearità delle equazioni differenziali, la sequenza temporale può essere calcolata simultaneamente su GPU mediante l'algoritmo di *Associative Parallel Prefix Scan* in tempo $\mathcal{O}(S)$.

Il Limite Fisico degli SSM a Stati Reali

Nei modelli a stati reali (quali Mamba/S6 o S4), gli autovalori della matrice di transizione $\bar{A}$ devono essere strettamente minori di 1 per garantire la stabilità asintotica del sistema dinamico:


$$h_t = \sum_{\tau=1}^t \bar{A}^{t-\tau} \bar{B}x_\tau$$

L'operatore di transizione $\bar{A}$ agisce quindi primariamente come un **filtro a decadimento esponenziale reale**. Questo comportamento smorza monotonamente il segnale nel passato: risulta estremamente complesso per il modello apprendere dinamiche di *coerenza di fase armonica periodica* o mantenere correlazioni sintattiche a lungo raggio che richiederebbero interferenze costruttive e distruttive stabili nel tempo.

4. FSTLLM 2.0: Fourier Space-Time State Space Model

L'architettura **FSTLLM 2.0 (Fourier Space-Time LLM)** nasce specificamente per superare i limiti dei decadimenti reali monotoni, introducendo la **meccanica ondulatoria complessa** all'interno dello spazio di stato. I vettori di memoria non decadono unicamente per smorzamento, ma vengono incisi e modulati come **fasori complessi sul cerchio unitario**:

$$\mathbb{S}^1 = \{z \in \mathbb{C} \mid |z| = 1\}$$



4.1 I Token di Ingresso mantengono il Vettore di Embedding Reale?

Sì, in modo categorico. All'ingresso del modello, il token discreto non viene convertito in entità esoteriche:

$$\mathbf{x} = \text{Embedding}(\text{token}_t) \in \mathbb{R}^{d_{\text{model}}}$$

Nel codice di `model.py` (FourierSpaceTimeLLM_V2):

```
self.token_emb = nn.Embedding(vocab_size, d_model)
x = self.token_emb(idx)
```

I token vivono nello spazio vettoriale reale classico $\mathbb{R}^D$. I numeri complessi e i fasori non sostituiscono la rappresentazione semantica del vocabolario, ma entrano in gioco **esclusivamente all'interno del layer ricorrente come operatore di transizione dinamica temporale**.

4.2 La Convoluzione Locale Depthwise 1D (Kernel 4)

I modelli spettrali globali puri rischiano di non distinguere accuratamente relazioni di prossimità immediata (ad esempio la correlazione stretta tra un articolo e il sostantivo subito adiacente). In FSTLLM 2.0, prima delle proiezioni, l'input viene filtrato da una convoluzione 1D causale depthwise con kernel $K = 4$:

$$\mathbf{x}_{\text{conv}} = \text{SiLU}(\text{Conv1D}(\mathbf{x}))$$

- In addestramento viene calcolata causalmente in parallelo su tutta la sequenza.
- In inferenza step-by-step $\mathcal{O}(1)$, il modello mantiene un micro-buffer di soli $K - 1 = 3$ vettori, garantendo un costo computazionale costante indipendente dalla lunghezza del testo.

4.3 Il Parametro θ (Fase) è un Parametro Fisso in Più?

No, θ (o Φ_t) non è un peso statico memorizzato per posizione, ma un angolo cumulativo modulato dinamicamente. La fase totale al passo t è data dall'integrazione:

$$\Phi_t = \Phi_{t-1} + \omega_{\text{base}} + \Delta\theta_t$$

dove:

1. ω_{base} (**Buffer Statico non Apprendibile**): È una griglia di frequenze armoniche precalcolata e fissata da 0.01 a π lungo le dimensioni interne della testa (`head_dim`):

```
freqs = torch.linspace(0.01, math.pi, self.head_dim)
self.register_buffer("base_freqs", freqs.view(1, 1, 1, self.head_dim))
```

2. $\Delta\theta_t$ (**Modulazione di Fase Selettiva**): È calcolata all'istante dall'input corrente tramite la proiezione lineare apprendibile `phase_proj`:

$$\Delta\theta_t = \pi \tanh(W_\varphi \mathbf{x}_{\text{conv}})$$

La rete impara la matrice W_φ , che stabilisce **come accelerare o rallentare la rotazione di fase** in funzione del significato semantico del token (meccanismo analogo alla modulazione di Δ in Mamba).

4.4 Come interagiscono Teste Diverse tra Q e KV? (Meccanismo GQR e `repeat_interleave`)

Una delle domande più frequenti in sede di discussione riguarda l'interazione tra insiemi di disuguali di teste: **se disponiamo di 8 teste di Query e solo 2 teste di Memoria (KV), come possono moltiplicarsi se hanno dimensionalità diverse?**

L'Analogia della Biblioteca: 2 Archivi di Memoria e 8 Ricercatori

Immaginiamo la memoria del modello come una biblioteca specializzata:

- **Le teste KV rappresentano gli Archivi di Memoria:** ne costruiamo solo 2 (KV_0 e KV_1), riducendo l'impronta di memoria di un fattore 4. Ciascun archivio condensa una prospettiva temporale della storia della conversazione.
- **Le teste Q rappresentano i Ricercatori Specializzati:** ne assegniamo 8 ($Q_0, Q_1, \dots, Q_7$), ciascuno istruito a estrarre una specifica relazione (sintassi, legami anaforici, entità nominate, tono emotivo).

Invece di costruire 8 mastodontici archivi ridondanti, i ricercatori lavorano in **gruppi di 4 sullo stesso archivio**:

$$[Q_0, Q_1, Q_2, Q_3] \rightarrow \text{interrogano } KV_0, \quad [Q_4, Q_5, Q_6, Q_7] \rightarrow \text{interrogano } KV_1$$

Il Meccanismo Matematico dei Tensori nel Codice (`model.py`)

Nel forward di `SelectiveFourierWaveLayerV2`, il mismatch dimensionale viene risolto elegantemente tramite la duplicazione causale broadcasted (**`repeat_interleave`**):

1. Proiezioni Lineari Asimmetriche:

$$\mathbf{q} = W_Q \mathbf{x}_{\text{conv}} \in \mathbb{R}^{B \times S \times 8 \times 48}$$

$$k = W_K x_{\text{conv}} \in \mathbb{R}^{B \times S \times 2 \times 48}, \quad v = W_V x_{\text{conv}} \in \mathbb{R}^{B \times S \times 2 \times 48}$$

2. **Aggiornamento Compatto dello Stato Ricorrente:** Lo stato olografico memorizza unicamente le 2 teste KV:

$$S_t \in \mathbb{C}^{B \times 2 \times 48}$$

Durante l'inferenza, occupiamo solo $2 \times 48 = 96$ numeri complessi per token invece di 384.

3. **Espansione Dinamica (repeat_interleave):** Per consentire la risonanza con le 8 Query, il tensore dello stato viene espanso lungo la dimensione delle teste:

```
# Ogni testa KV viene replicata per 8 // 2 = 4 Query:
state_expanded = f_state.repeat_interleave(4, dim=2) # Forma: (B, 8, 48)
carrier_pos_exp = carrier_pos.repeat_interleave(4, dim=2)
```

4. **Demodolazione di Risonanza Elemento-per-Elemento:**

$$y_t = \text{Re}\left((Q_t \odot e^{j\Phi_t}) \odot S_t^{\text{expanded}}\right) \in \mathbb{R}^{B \times S \times 8 \times 48}$$

Il risultato viene poi compattato a $d_{\text{model}} = 384$ e proiettato in uscita tramite W_O .

Perché questa asimmetria è lo Standard Moderno (LLaMA 3, Mistral, FSTLLM 2.0)?

La ricerca empirica su larga scala (Ainslie et al., GQA) ha dimostrato che la memoria del testo passata possiede una ridondanza intrinseca: mantenere decine di matrici di chiave e valore duplicate spreca banda di memoria senza aumentare l'accuratezza. Al contrario, mantenere una **molteplicità di Query** permette al modello di estrarre rappresentazioni eterogenee dallo stesso compatto substrato di memoria.

4.5 Aggiornamento dello Stato Olografico Ricorrente

L'equazione che regola l'evoluzione temporale della memoria è:

$$S_t = S_{t-1} \odot \gamma_t + (1 - \gamma_t)(K_t \odot V_t \odot e^{-j\Phi_t})$$

dove:

- $\gamma_t = \sigma(W_d x_{\text{conv}})$ è il coefficiente di decadimento selettivo.
- $e^{-j\Phi_t}$ è l'onda portante coniugata che incide spettralmente l'informazione $K_t \odot V_t$.
- In inferenza l'operazione costa un singolo prodotto elemento-per-elemento in tempo $\mathcal{O}(1)$. In addestramento si calcola in parallelo tramite una matrice triangolare inferiore associativa.

5. Tavola Sinottica Comparativa tra i Modelli

La seguente tabella offre la sintesi comparativa ideale da esporre alla commissione o proiettare durante l'esame:

Proprietà	Transformer (GPT-3/4)	Mamba (S6)	RWKV-6 (Eagle)	FSTLLM 2.0 (No-stro)
Complessità Training	$\mathcal{O}(S^2)$ (Quadratica)	$\mathcal{O}(S)$ (Lineare)	$\mathcal{O}(S)$ (Lineare)	$\mathcal{O}(S)$ (Prefix-Scan)
Complessità Inferenza	$\mathcal{O}(S)$ (Crescente)	$\mathcal{O}(1)$ (Costante)	$\mathcal{O}(1)$ (Costante)	$\mathcal{O}(1)$ (Strettamente Costante)
Memoria Inferenza	Esplosione KV-Cache ($\mathcal{O}(S)$)	Fisso $\mathcal{O}(1)$ (Vettore h)	Fisso $\mathcal{O}(1)$ (Matrice W)	Fisso $\mathcal{O}(1)$ (Ologramma S)

Dominio dello Stato	Attivazioni passate discrete	Vettori continui reali $\mathbb{R}^N$	Matrici reali $\mathbb{R}^{D \times D}$	Fasori sul cerchio $\mathbb{S}^1$
Dinamica Temporale	Allineamento QK^T + Softmax	Decadimento $\exp(\Delta A)$ reale	Time-mixing esponenziale	Interferenza d'onda + $\Delta\theta_t$
Configurazione Teste	Multi-Head (es. 96 teste)	1 stato per canale	Canali indipendenti	GQR (8 Query / 2 Memoria)
Sintassi Locale	Positional embedding	Conv1D causale iniziale	Time-shift operator	Depthwise Conv1D causale
Vincolo Hardware	Memory-Bandwidth Bound	Compute-Bound	Compute-Bound	Compute-Bound (Zero-Cache)

6. Analisi dei Parametri del Layer FSTLLM 2.0

Nel blocco `SelectiveFourierWaveLayerV2` (configurazione di riferimento con $d_{\text{model}} = 384$, $H = 8$, $KV_H = 2$, $HD = 48$):

- **Proiezione Query (W_Q):** $384 \times 384 = 147.456$ parametri.
- **Proiezione Key (W_K):** $384 \times (2 \times 48) = 384 \times 96 = 36.864$ parametri (−75% rispetto a MHA).
- **Proiezione Value (W_V):** $384 \times 96 = 36.864$ parametri.
- **Modulazione di Fase (W_φ):** $384 \times 96 = 36.864$ parametri.
- **Decadimento Selettivo (W_d):** $384 \times 2 = 768$ parametri.
- **Convoluzione Depthwise Locale:** $384 \times 1 \times 4 = 1.536$ parametri.
- **Proiezione di Uscita (W_O) e Gate (W_G):** $2 \times (384 \times 384) = 294.912$ parametri.

Risultato: L'approccio GQR libera parametri dall'infrastruttura di conservazione del contesto per reinvestirli nelle Query e nella rete non-lineare SwiGLU FFN, massimizzando il potere espressivo a parità di budget computazionale.

7. Benchmark e Confronto Sperimentale a 30M di Parametri (Letteratura arXiv)

Nello studio delle architetture neurali, testare modelli su una scala controllata di **circa 30 Milioni di parametri** rappresenta la metodologia accademica ideale per isolare i meriti dell'innovazione architeturale dai semplici effetti di scala legati alla potenza di calcolo grezza.

Nella cartella `paper_confronto/` sono stati raccolti e analizzati i paper fondanti della letteratura con cui confrontare FSTLLM 2.0:

1. **Mamba: Linear-Time Sequence Modeling with Selective State Spaces (Gu & Dao, 2023 - arXiv:2312.00752):**
 - Dimostra l'efficacia del meccanismo selettivo nei compiti di **Selective Copying** e **Induction Heads**, evidenziando i limiti dei modelli LTI (Linear Time-Invariant).
 - Offre il termine di paragone per misurare il throughput di generazione $\mathcal{O}(1)$ e la capacità di filtro del contesto.
2. **TinyStories: How Small Can Language Models Be and Still Speak Coherent English? (Eldan & Li, 2023 - arXiv:2305.07759):**
 - Dimostra che modelli compresi tra **1M e 33M di parametri** (basati su Transformer standard tipo GPT-Neo/GPT-2 a 28M/33M parametri) sono in grado di apprendere sintassi, coerenza logica e ragionamento causale se addestrati su un vocabolario controllato.

- Fornisce il **benchmark primario** su cui allenare e confrontare direttamente FSTLLM 2.0 (~30M parametri) con un Transformer classico di pari taglia.
3. **RWKV: Reinventing RNNs for the Transformer Era (Peng et al., 2023 - arXiv:2305.13048):**
 - Confronta architetture ricorrenti lineari e Transformer su scale a partire da **14M, 70M, 169M e 430M** di parametri su task NLP classici (LAMBADA, PIQA, StoryCloze).
 - Valuta la stabilità numerica del decadimento temporale per canale rispetto a modelli attention.
 4. **Transformers are SSMs: Structured State Space Duality (Dao & Gu, 2024 - arXiv:2405.21060 - Mamba-2):**
 - Formalizza il legame teorico (State Space Duality, SSD) tra la moltiplicazione di matrici semidense causali e le forme canoniche degli spazi di stato, offrendo il formalismo per interpretare la risonanza armonica come forma strutturata di attenzione lineare.
 5. **MobileLLM: Optimizing Sub-Billion Language Models (Meta AI, 2024 - arXiv:2402.14905):**
 - Analizza la massimizzazione del parametro-budget sotto il miliardo di pesi tramite Grouped-Query Attention (GQA) e deep-and-thin design.
 6. **Attention Is All You Need (Vaswani et al., 2017 - arXiv:1706.03762):**
 - Il punto di riferimento immutabile per la formulazione del Transformer standard.

Protocollo Sperimentale Raccomandato per FSTLLM 2.0 (30M)

Per la tesi o la presentazione universitaria, si raccomanda di impostare il confronto empirico su tre prove:

- **1. Language Modeling su TinyStories (30M Parametri):** Addestrare FSTLLM 2.0 ($d_{\text{model}} = 384$, 6 layer, $H = 8$, $KV_H = 2$) contro un Transformer equivalente a 6 layer. Verificare che la perplexity e la qualità generativa siano comparabili.
- **2. Long-Range Needle-In-A-Haystack (NIAH):** Posizionare un'informazione specifica all'interno di un contesto sintetico esteso (da 1k fino a 16k token) e testare la capacità della risonanza di fase nel recuperare il fatto senza degradazione d'ampiezza.
- **3. Benchmark di Inferenza e VRAM:** Misurare la memoria consumata al crescere della sequenza generata ($S = 128, 512, 2048, 8192$), dimostrando sperimentalmente la **curva perfettamente orizzontale** $\mathcal{O}(1)$ di FSTLLM 2.0 rispetto alla crescita lineare ripida del Transformer con KV-Cache.

8. Guida Strategica per la Presentazione Orale all'Università

Per condurre una discussione accademica impeccabile, si raccomanda di strutturare il discorso in **quattro passaggi sequenziali**:

1. **Il Paradosso del Transformer:** Lodare la capacità dei Transformer nel catturare il contesto, ma evidenziare subito il collo di bottiglia reale: l'attenzione $S \times S$ diventa ingestibile per contesti di milioni di parole e il KV-Cache satura la memoria delle schede grafiche. Usare la metafora di 3Blue1Brown: *"Nei Transformer ogni parola, per essere interpretata, deve stringere la mano a tutte le parole del passato"*.
2. **La Promessa degli SSM e il loro Limite Reale:** Mostrare come i modelli a spazio di stato comprimano la storia in un vettore compatto ad inferenza $\mathcal{O}(1)$. Evidenziare tuttavia che matrici reali $\bar{A}$ con autovalori < 1 equivalgono a un decadimento esponenziale monotono, incapace di preservare la periodicità e le interferenze di fase armonica a lungo raggio.
3. **L'Innovazione di FSTLLM 2.0:** Presentare la modulazione di fasori sul cerchio unitario S^1 . Spiegare che:

- I token rimangono vettori continui reali.
- La convoluzione 1D locale cattura la sintassi immediata (articoli e desinenze).
- La fase non è statica ma guidata selettivamente dal contenuto del testo ($\Delta\theta_t$).
- Il Grouped-Query Resonance (GQR) permette a 4 teste di Query di interrogare simultaneamente lo stesso ologramma di memoria (KV_0, KV_1).

4. Risposte Chiare alle Domande Tipiche della Commissione:

- **Domanda:** “Perché usare numeri complessi sul cerchio unitario?”

Risposta: Il fasore $e^{j\Phi}$ possiede modulo unitario $|e^{j\Phi}| = 1$. A differenza dei coefficienti reali che smorzano il segnale portando a vanishing gradient, la rotazione di fase preserva rigorosamente l’energia, consentendo fenomeni di interferenza costruttiva e distruttiva a distanza temporale arbitraria.

- **Domanda:** “Come garantite la causalità se il training avviene in parallelo?”

Risposta: La causalità è garantita a monte dalla convoluzione causale (con padding asimmetrico a sinistra) e a valle dalla struttura triangolare inferiore della matrice di decadimento spettrale, impedendo qualunque trapelamento di informazione futura.

- **Domanda:** “Che differenza c’è tra RoPE (Rotary Position Embedding) e FSTLLM 2.0?”

Risposta: RoPE applica una rotazione deterministica fissa basata sulla posizione aritmetica assoluta del token. In FSTLLM 2.0, l’avanzamento di fase $\Delta\theta_t$ è un parametro **selettivo dipendente dai dati** appreso dalla rete, consentendo al modello di accelerare o congelare la frequenza in base alla semantica della frase.

9. Conclusioni

Il modello **FSTLLM 2.0** coniuga la solidità teorica dell’analisi armonica di Fourier con le esigenze architetturali dell’intelligenza artificiale generativa moderna. Garantendo inferenza strettamente $\mathcal{O}(1)$, addestramento parallelo $\mathcal{O}(S)$ e un’espressività ondulatoria complessa, l’architettura si candida come alternativa concreta ed elegante ai tradizionali meccanismi di Softmax Attention per l’elaborazione di sequenze a lunghissimo contesto.