

Progetto 21.0: Fourier Associative Matrix LLM (FAM-LLM)

Sblocco della Capacità di Ragionamento nei Modelli Sub-Quadratici tramite Memoria Associativa Matriciale Complessa ($K^\dagger \otimes V$) e Onde di Fourier

Autore: Giovanni & Team Fourier LLM

Data: Settembre - Ottobre 2026

Scala di Riferimento: GPT-2 (50.257 Token Vocabulary, $d_{\text{model}} = \frac{384}{768}$)

Sommario (Abstract)

I modelli linguistici sub-quadratici ricorrenti e a onde di Fourier (FSTLLM v1, v2) hanno introdotto l'inferenza a costo costante $\mathcal{O}(1)$ e il training quasi-lineare $\mathcal{O}(N \log N)$. Ciononostante, l'adozione del prodotto di Hadamard (element-wise) per l'accumulazione dello stato spettrale ha storicamente imposto un grave **Capacity Bottleneck**: comprimere la storia di una sequenza in un vettore 1D di dimensione D limita drasticamente i gradi di libertà a disposizione del modello, provocando interferenze distruttive delle fasi e rapido oblio associativo (**catastrophic forgetting**). In questo lavoro presentiamo il **Progetto 21.0: Fourier Associative Matrix LLM (FAM-LLM)**. L'architettura sostituisce la compressione vettoriale con un operatore di memoria associativa matriciale complessa:

$$M_t = K_{C,t}^\dagger \otimes V_{C,t} \in \mathbb{C}^{\text{HD}} \times \text{HD}$$

L'aggiornamento dello stato cumulativo opera come un tensore di correlazione hebbiana continua, scalando la capacità di memorizzazione locale da $\mathcal{O}(\text{HD})$ a $\mathcal{O}(\text{HD}^2)$ per ciascuna testa. La complessità computazionale rispetto alla lunghezza del contesto N resta strettamente lineare $\mathcal{O}(N)$ in fase di training (grazie alla formulazione a scansione parallela per blocchi **Chunked Scan**) e $\mathcal{O}(1)$ costante in inferenza per singolo token generato.

1. Il Limite dei Modelli Ricorrenti a Vettore 1D

Nelle formulazioni precedenti (V1, V2 e modelli SSM element-wise come RWKV-4), l'aggiornamento dello stato era descritto da:

$$s_t = \gamma_t \cdot s_{t-1} + (1 - \gamma_t) \cdot ((k_t \cdot e^{-i\theta_t}) \cdot v_t) \in \mathbb{C}^{\text{HD}}$$

Questa formulazione soffre di un'impossibilità algebrica:

- Mancanza di Interazione Incrociata (Rank-1 Vector Limit):** Il canale i -esimo della chiave k può interagire unicamente con il canale i -esimo del valore v . Non esiste un tensore di transizione in grado di memorizzare l'associazione "la parola A implica il concetto B".
- Saturazione di Fase:** La fase angolare $\theta \in [0, 2\pi)$ modula vettori su un cerchio unitario. Quando il numero di concetti supera la dimensione HD della testa, onde su frequenze simili provocano battimenti o cancellazioni distruttive complete.

2. Formulazione Matematica di FAM-LLM 21.0

2.1 Onde di Fase e Proiezioni

Dato il vettore di attivazione $x_t \in \mathbb{R}^D$, estraiamo tramite proiezioni lineari:

$$Q_t = x_t W_Q, \quad K_t = x_t W_K, \quad V_t = x_t W_V$$

La derivata di fase istantanea $\Delta\theta_t = \pi \tanh(x_t W_\theta)$ guida l'oscillatore complesso:

$$\theta_t = \theta_{t-1} + \omega_{\text{base}} + \Delta\theta_t$$

$$K_{\mathbb{C},t} = K_t \cdot e^{-i\theta_t}, \quad Q_{\mathbb{C},t} = Q_t \cdot e^{i\theta_t}$$

2.2 Il Salto di Memoria: Outer Product Matriciale

Invece del prodotto di Hadamard element-wise, calcoliamo il prodotto tensoriale esterno (outer product):

$$M_t = K_{\mathbb{C},t}^\dagger \otimes V_{\mathbb{C},t} \in \mathbb{C}^{\text{HD} \times \text{HD}}$$

dove $\dagger$ indica la trasposta coniugata hermitiana. La memoria associativa si aggiorna ricorsivamente tramite:

$$S_t = \gamma_t \cdot S_{t-1} + (1 - \gamma_t) \cdot M_t$$

2.3 Estrazione Associativa (Query Readout)

All'arrivo della Query complessa $Q_{\mathbb{C},t} \in \mathbb{C}^{\text{HD}}$, l'estrazione non è un filtro element-wise ma un vero **prodotto vettore-matrice**:

$$Y_t = \text{Re}(Q_{\mathbb{C},t} \cdot S_t) \in \mathbb{R}^{\text{HD}}$$

Per la proprietà associativa:

$$Q_t \cdot \left(\sum_{\tau} K_{\tau}^\dagger V_{\tau} \right) = \sum_{\tau} (Q_t K_{\tau}^\dagger) V_{\tau}$$

Il modello recupera la capacità espressiva tipica dei Transformer (confronto scalare di risonanza tra Q e tutte le K storiche), ma **senza dover memorizzare la sequenza di token**, poiché la storia è compressa nella matrice compatta S .

3. Complessità e Prestazioni a Confronto

Proprietà	Transformer Standard	Vecchio LLM	Fourier (V2)	Progetto 21.0 (FAM-LLM)
Forma dello Stato	KV Cache ($N \times D$)	Vettore 1D compresso (D)		Matrice Associativa ($\text{HD} \times \text{HD}$)
Capacità di Memoria	$\mathcal{O}(N \cdot D)$	$\mathcal{O}(D)$ (Bottleneck)		$\mathcal{O}(D^2)$ per testa (Elevata)
Complessità Training	$\mathcal{O}(N^2 \cdot D)$ (Quadratica)	$\mathcal{O}(N \log N)$		$\mathcal{O}(N \cdot D^2)$ (Lineare in N)
Complessità Generazione	$\mathcal{O}(N)$ per token (Degrada)	$\mathcal{O}(1)$ per token		$\mathcal{O}(1)$ per token (Costante)
VRAM a $N = 32.000$ tk	14 GB (Esplosione)	0.5 GB		0.6 GB (Strettamente Costante)

4. Conclusioni

Il Progetto 21.0 unifica la purezza della fisica delle onde di Fourier con la robustezza matematica della Linear Attention e dei sistemi associativi hebbiani. Il modello mantiene intatta la velocità e l'efficienza $\mathcal{O}(1)$ in inferenza, offrendo al contempo lo spazio di rappresentazione matriciale necessario per il ragionamento elaborato e l'in-context learning.